

Нейронные сети

Лекция 3. Линейная регрессия

Бабин Д.Н., **Иванов И.Е.**, Петюшко А.А.

кафедра Математической Теории Интеллектуальных Систем

27 сентября 2021г.



- 1 Оптимальный байесовский регрессор
- 2 Линейная регрессии с точки зрения ML и MAP оценивания
- 3 Регуляризация: гребневая регрессия, LASSO, ElasticNet



Напоминание: вероятностная постановка задач машинного обучения

Предположения

Пусть известно совместное распределение $p(x, y)$ на $X \times Y$

Пусть задана функция потерь $L(a(x), y)$

Определение

Средняя величина потерь для алгоритма $a(x)$

$$R(a) = \iint L(a(x), y) dP(x, y) = \iint L(a(x), y) p(x, y) dx dy$$

Задача

Найти такой $a^*(x)$, что $a^*(x) = \arg \min_a R(a)$.

Будем называть модель a^* оптимальной и R^* — значение оптимального среднего риска.

Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при



Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$



Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$

Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$



Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$

Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$

Доказательство

$$E((y - a(x))^2|x) = E((y - E(y|x) + E(y|x) - a(x))^2|x) =$$

Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$

Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$

Доказательство

$$\begin{aligned} E((y - a(x))^2|x) &= E((y - E(y|x) + E(y|x) - a(x))^2|x) = \\ &= E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x) - 2E(y - E(y|x)|x)E(a(x) - E(y|x)|x) \end{aligned}$$

Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$

Лемма

$$E((y - a(x))^2|x) = E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x)$$

Доказательство

$$\begin{aligned} E((y - a(x))^2|x) &= E((y - E(y|x) + E(y|x) - a(x))^2|x) = \\ &= E((y - E(y|x))^2|x) + E((a(x) - E(y|x))^2|x) - 2E(y - E(y|x)|x)E(a(x) - E(y|x)|x) \end{aligned}$$

Последнее слагаемое равно нулю, так как

$$E(y - E(y|x)|x) = E(y|x) - E(E(y|x)|x) = E(y|x) - E(y|x) = 0.$$

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$



Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$

Доказательство

$$R(a) = \iint L(a(x), y)p(x, y)dydx = \iint (a(x) - y)^2 p(x, y)dydx =$$



Квадратичная функция потерь

Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$

Доказательство

$$\begin{aligned} R(a) &= \iint L(a(x), y) p(x, y) dy dx = \iint (a(x) - y)^2 p(x, y) dy dx = \\ &= \iint (a(x) - y)^2 p(y|x) dy p(x) dx = \int E((y - a(x))^2 | x) p(x) dx \end{aligned}$$



Теорема

Если $L(a(x), y) = (a(x) - y)^2$, то величина средних потерь минимальна при

$$a^* = E(y|x)$$

Доказательство

$$R(a) = \iint L(a(x), y) p(x, y) dy dx = \iint (a(x) - y)^2 p(x, y) dy dx =$$
$$= \iint (a(x) - y)^2 p(y|x) dy p(x) dx = \int E((y - a(x))^2 | x) p(x) dx$$
 Применяя лемму, получаем:
$$R(a) = \int E((y - a(x))^2 | x) p(x) dx = \int E((y - E(y|x))^2 | x) p(x) dx +$$
$$\int E((a(x) - E(y|x))^2 | x) p(x) dx \geq \int E((y - E(y|x))^2 | x) p(x) dx,$$
 что и требовалось доказать.





Постановка задачи: линейная регрессия


Дано

$$p(y_i|x_i) \sim w^T x_i + \varepsilon_i \sim N(w^T x_i, \sigma^2),$$

для $i = 1.., \ell$, где $w \in \mathbb{R}^{n+1}$, $\varepsilon_i \sim N(0, \sigma^2)$

Задача

Найти w



Принцип максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$



Напоминание: два вида оценивания параметров

Принцип максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

Принцип максимума апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x, y)$$



Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$



Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$



Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$

$$p(y_i|w, x_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$



Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$

$$p(y_i|w, x_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$

$$w_{ML} = \arg \max_w \prod_i \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right) = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2}$$



Оценка максимального правдоподобия

$$w_{ML} = \arg \max_w p(y|w, x)$$

$$w_{ML} = \arg \max_w \prod_i p(y_i|w, x_i)$$

$$p(y_i|w, x_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right)$$

$$w_{ML} = \arg \max_w \prod_i \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y_i - w^T x_i)^2}{2\sigma^2}\right) = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2}$$

$$w_{ML} = \arg \min_w \sum_i (y_i - w^T x_i)^2$$



Постановка задачи и допущения

- $X = \mathbb{R}^n$, $Y = \mathbb{R}$



Постановка задачи и допущения

- $X = \mathbb{R}^n$, $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$, где $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$ — параметры модели.



Постановка задачи и допущения

- $X = \mathbb{R}^n$, $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$, где $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$ — параметры модели.
- Удобно писать в векторном виде

$$a(x) = w^T \cdot x,$$

где $x = (1, x^1, \dots, x^n)^T \in \mathbb{R}^{n+1}$.



Метод наименьших квадратов

Постановка задачи и допущения

- $X = \mathbb{R}^n$, $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$, где $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$ — параметры модели.
- Удобно писать в векторном виде

$$a(x) = w^T \cdot x,$$

где $x = (1, x^1, \dots, x^n)^T \in \mathbb{R}^{n+1}$.

Метод наименьших квадратов

- $L(w, X_{train}) = MSE(w, X_{train}) = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2$ — функция потерь

Метод наименьших квадратов

Постановка задачи и допущения

- $X = \mathbb{R}^n$, $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$, где $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$ — параметры модели.
- Удобно писать в векторном виде

$$a(x) = w^T \cdot x,$$

где $x = (1, x^1, \dots, x^n)^T \in \mathbb{R}^{n+1}$.

Метод наименьших квадратов

- $L(w, X_{train}) = MSE(w, X_{train}) = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2$ — функция потерь
- Задача найти $\hat{w} = \arg \min_w (L(w, X_{train}))$

Теорема

Решением задачи $\arg \min_w \left(\sum_{i=1}^{\ell} (w^T \cdot x_i - y_i)^2 \right)$ является $\hat{w} = (X^T X)^{-1} \cdot X^T \cdot y$, где $X_{i,j} = x_i^j$, $y = (y_1, \dots, y_{\ell})$.



Теорема

Решением задачи $\arg \min_w \left(\sum_{i=1}^{\ell} (w^T \cdot x_i - y_i)^2 \right)$ является $\hat{w} = (X^T X)^{-1} \cdot X^T \cdot y$, где $X_{i,j} = x_i^j$, $y = (y_1, \dots, y_{\ell})$.

Доказательство

Запишем задачу в векторном виде $\|Xw - y\|^2 \rightarrow \min_w$. Необходимое условие минимума в матричном виде имеет вид:

$$\begin{aligned} \frac{\partial}{\partial w} \|Xw - y\|^2 &= \frac{\partial}{\partial w} \left((Xw - y)^T \cdot (Xw - y) \right) = \frac{\partial}{\partial w} \left((Xw)^T Xw - (Xw)^T y - y^T Xw + y^T y \right) = \\ &= \frac{\partial}{\partial w} \left(w^T X^T Xw - w^T X^T y - y^T Xw + y^T y \right) = \frac{\partial}{\partial w} w^T (X^T X)w - 2 \frac{\partial}{\partial w} (X^T y)^T w = 0 \end{aligned}$$

Определение

Пусть $w = (w_1, \dots, w_n)$ — вектор столбец, а $z = z(w_1, \dots, w_n)$. Тогда определим

$$\frac{\partial z}{\partial w} := \left(\frac{\partial z}{\partial w_1}, \dots, \frac{\partial z}{\partial w_n} \right)^T$$

Лемма 1

$$\frac{\partial}{\partial x} x^T a = a$$

Лемма 2

$$\frac{\partial}{\partial x} x^T A x = (A + A^T)x$$

Теорема

Решением задачи $\arg \min_w (\sum_{i=1}^{\ell} (w^T \cdot x_i - y_i)^2)$ является $\hat{w} = (X^T X)^{-1} \cdot X^T \cdot y$, где $X_{i,j} = x_i^j$, $y = (y_1, \dots, y_{\ell})$.

Продолжение доказательства

Необходимое условие минимума в матричном виде имеет вид:

$$\frac{\partial}{\partial w} \|Xw - y\|^2 = \frac{\partial}{\partial w} w^T (X^T X) w - 2 \frac{\partial}{\partial w} (X^T y)^T w =$$

Далее применяем леммы и приравниваем к нулю:

$$= 2X^T Xw - 2X^T y = 0,$$

откуда получаем $w = (X^T X)^{-1} \cdot X^T \cdot y$, что и требовалось доказать.

Идея

Можно генерировать новые признаки на основе уже имеющихся, применяя нелинейные функции



Полиномиальная регрессия

Идея

Можно генерировать новые признаки на основе уже имеющихся, применяя нелинейные функции

Примеры преобразований

- Возведение в степень
- Парные произведения
- Квадратный корень
- Логарифм
- Экспонента



Преимущества и недостатки линейной регрессии



Преимущества

- Простой алгоритм, вычислительно не сложный
- Линейная регрессия хорошо интерпретируемая модель
- Несмотря на свою простоту может описывать довольно сложные зависимости (например, полиномиальные)



Преимущества и недостатки линейной регрессии

Преимущества

- Простой алгоритм, вычислительно не сложный
- Линейная регрессия хорошо интерпретируемая модель
- Несмотря на свою простоту может описывать довольно сложные зависимости (например, полиномиальные)

Недостатки

- Алгоритм предполагает, что все признаки числовые
- Алгоритм предполагает, что данные распределены нормально, что не всегда так
- Алгоритм сильно чувствителен к выбросам





Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$

$$w_{MAP} = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2} + \ell \ln p(w)$$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$

$$w_{MAP} = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2} + \ell \ln p(w)$$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \max_w p(w|x_1, \dots, x_\ell, y_1, \dots, y_\ell)$$

$$w_{MAP} = \arg \max_w \prod_i p(y_i|x_i, w)p(w)$$

$$w_{MAP} = \arg \max_w \sum_i \ln p(y_i|x_i, w) + \ln p(w)$$

$$w_{MAP} = \arg \max_w \sum_i -\frac{(y_i - w^T x_i)^2}{2\sigma^2} + \ell \ln p(w)$$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

В задаче минимизации появилось дополнительное слагаемое, которое зависит только от априорного распределения на веса w

Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

Предположим, что $p(w) \sim N(0, \tau^2)$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

Предположим, что $p(w) \sim N(0, \tau^2)$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \frac{\ell w^T w}{2\tau^2}$$



Метод максимизации апостериорной вероятности

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \ell \ln p(w)$$

Предположим, что $p(w) \sim N(0, \tau^2)$

$$w_{MAP} = \arg \min_w \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \frac{\ell w^T w}{2\tau^2}$$

$$w_{MAP} = \arg \min_w \frac{1}{\ell} \sum_i \frac{(y_i - w^T x_i)^2}{2\sigma^2} - \frac{1}{2\tau^2} \|w\|^2$$





L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \frac{\alpha}{2} \sum_{i=0}^n w_i^2 = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \frac{\alpha}{2} \sum_{i=0}^n w_i^2$ — функция потерь



L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \frac{\alpha}{2} \sum_{i=0}^n w_i^2 = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \frac{\alpha}{2} \sum_{i=0}^n w_i^2$ — функция потерь
- Задача найти $\hat{w} = \arg \min_w (L(w, X_{train}))$



L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \frac{\alpha}{2} \sum_{i=0}^n w_i^2 = \frac{1}{\ell} \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \frac{\alpha}{2} \sum_{i=0}^n w_i^2$ — функция потерь
- Задача найти $\hat{w} = \arg \min_w (L(w, X_{train}))$

Теорема

Решением задачи $\arg \min_w (\sum_{i=1}^{\ell} (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n w_i^2)$ является

$\hat{w} = (X^T X + \alpha I_{n+1})^{-1} \cdot X^T \cdot y$, где $X_{i,j} = x_i^j$, $y = (y_1, \dots, y_{\ell})$, I_{n+1} — единичная матрица.



Доказательство теоремы



Лемма 3

$$\frac{\partial}{\partial x} x^T x = 2x$$

Доказательство теоремы

Лемма 3

$$\frac{\partial}{\partial x} x^T x = 2x$$

Теорема

Решением задачи $\arg \min_w \left(\sum_{i=1}^{\ell} (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n w_i^2 \right)$ является

$\hat{w} = (X^T X + \alpha I_{n+1})^{-1} \cdot X^T \cdot y$, где $X_{i,j} = x_i^j$, $y = (y_1, \dots, y_{\ell})$, I_{n+1} — единичная матрица.

Доказательство

Запишем задачу в векторном виде $\|Xw - y\|^2 + \alpha \|w\|^2 \rightarrow \min_w$. Необходимое условие минимума в матричном виде имеет вид:

$$\frac{\partial}{\partial w} \left((Xw - y)^T \cdot (Xw - y) + \alpha w^T w \right) = 2X^T Xw - 2X^T y + 2\alpha w = 0$$

- Регуляризация не даёт параметрам модели быть слишком большими
- Как правило регуляризация обеспечивает большую обобщающую способность
- Более устойчива к выбросам
- Появился параметр, который можно настроить при помощи кросс-валидации



Свойства гребневой регрессии

- Регуляризация не даёт параметрам модели быть слишком большими
- Как правило регуляризация обеспечивает большую обобщающую способность
- Более устойчива к выбросам
- Появился параметр, который можно настроить при помощи кросс-валидации

Вероятностный смысл параметра α

$\alpha = \frac{1}{\tau^2}$, где τ — среднеквадратическое отклонение априорного распределения на w



L1-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \alpha \sum_{i=0}^n |w_i| = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i|$ — функция потерь



L1-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \alpha \sum_{i=0}^n |w_i| = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i|$ — функция потерь
- Задача найти $\hat{w} = \arg \min_w (L(w, X_{train}))$



L1-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + \alpha \sum_{i=0}^n |w_i| = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i|$ — функция потерь
- Задача найти $\hat{w} = \arg \min_w (L(w, X_{train}))$

Свойства

- Эта регуляризация обеспечивает отбор признаков
- Нет аналитического решения




Вероятностный смысл параметра α

Параметр α — обратно пропорционален среднеквадратичному отклонению априорного распределения на w . В данном случае это распределение Лапласа

$$p(w) = \frac{1}{\tau} \exp\left(-\frac{\|w\|}{2\tau}\right)$$



Интуиция отбора признаков при L1-регуляризации



L1-регуляризация и L2-регуляризация

- $$L(w, X_{train}) = MSE(w, X_{train}) + r\alpha \sum_{i=0}^n |w_i| + (1 - r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2 =$$
$$\sum_i (w^T \cdot x^{(i)} - y_i)^2 + r\alpha \sum_{i=0}^n |w_i| + (1 - r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2 - \text{функция потерь}$$



L1-регуляризация и L2-регуляризация

- $L(w, X_{train}) = MSE(w, X_{train}) + r\alpha \sum_{i=0}^n |w_i| + (1 - r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2 =$
 $\sum_i (w^T \cdot x^{(i)} - y_i)^2 + r\alpha \sum_{i=0}^n |w_i| + (1 - r)\frac{\alpha}{2} \sum_{i=0}^n w_i^2$ — функция потерь
- Задача найти $\hat{w} = \arg \min_w (L(w, X_{train}))$

Свойства

- Нет аналитического решения
- Совмещает положительные свойства гребневой регрессии и LASSO.



- Линейная регрессия — простая, хорошо интерпретируемая модель, не устойчивая к выбросам
- Имеет наглядную вероятностную интерпретацию
- Регуляризация — отличный способ борьбы с переобучением и шумом в данных



